Partage de connaissances - Master MIASHS

Gérer les dépendances d'un projet Python

Python et les librairies Python évoluent rapidement:

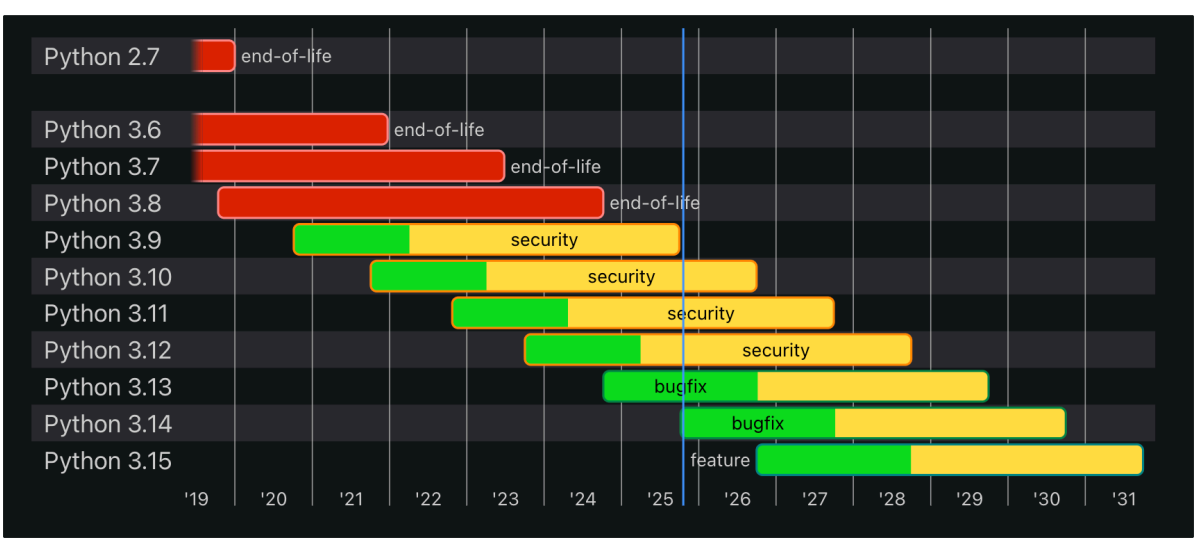

Un code écrit pour `pandas 1.0` ne fonctionera probablement pas avec `pandas 2.0`.

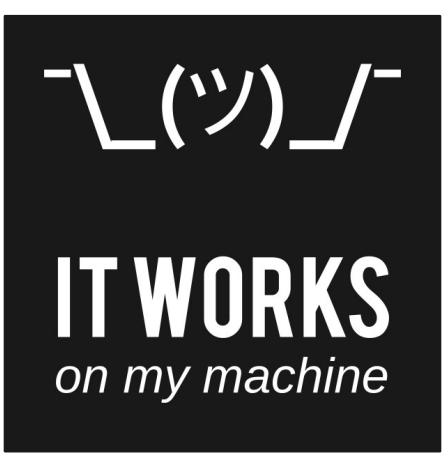

On a besoin d'expliciter les dépendances utilisées par un projet afin de garantir la reproductibilité de l'environnement d'exécution.

`uv` est devenu le principal outil pour gérer les environnements (remplace progressivement `conda`).

```
# Créer un environnement virtuel
uv init

# Ajouter des dépendances
uv add pandas

# Activer l'environnement dans VS Code ou dans le terminal
.venv\Scripts\activate      # Windows (PowerShell)
source .venv/bin/activate   # MacOS

# Synchronise l'environnement virtuel avec le `uv.lock`
uv sync

# uvx permet d'exécuter "à la volée" des commandes dépendant de libraries Python
uvx marimo edit
```

Utiliser le terminal

```
# Se déplacer dans un dossier
cd ./dossier
# Et revenir au dossier parent
cd ..

# Flèche ⬆️ / ⬇️ pour se déplacer dans l'historique
# CTRL + C pour interrompre une commande en cours d'exécution

# Ouvrir le dossier dans VS Code (-r pour ouvrir dans la fenêtre actuel VS Code)
code . -r

# MacOS - définir des alias
alias c='code . -r'
alias cdmaster='cd "/Users/mathisderenne/Documents/02 - Scolaire/M2 MIASHS/"'
alias cdgh='cd /Users/mathisderenne/GitHub/'

# Windows (PowerShell) - définir des alias
function c { code . -r }
function cdgh { cd "C:/Users/mathisderenne/GitHub" }
```

Améliorer son expérience dans le terminal en installant un shell: https://starship.rs/

Partager et collaborer sur du code

`Git` : permet de versionner un dossier:

- tutoriel interactif pour apprendre à maîtriser Git
- interface de l'extension VS Code Git

`Git` ≠ `GitHub` / `GitLab` : plateforme d'hébergement de projets Git

Quelques conventions sur la structure des projets Git:

- `README.md` décrit le projet
- `.gitignore` précise les éléments ignorés par Git
- dossiers courant:
  - `./src` : code source du projet
  - `./assets` : images, logos
  - `./docs`, `./data`, `./test`

`GitHub Pages` permet d'héberger une page statique gratuitement → utile pour CV en ligne (tutoriel en 5 minutes) / projets démos.

VS Code

- éditer les notebooks (Python et R)
- formatter le code automatiquement (extension Ruff)
- lire des fichiers PDF (extension PDF Viewer)
- explorer des fichiers de données tabulaires (extension Data Wrangler)
- GitHub Copilot (gratuit pour les étudiants)
- mes settings.json

Positron: nouveau IDE pour R

Rédaction scientifique et communication autour de projets data

- rédiger rapport de stage/alternance: **Typst** (extension Tinymist)
- présenter des projets data avec **MystMD**
- créer des diagrammes avec **Mermaid** (Mermaid Live Editor)

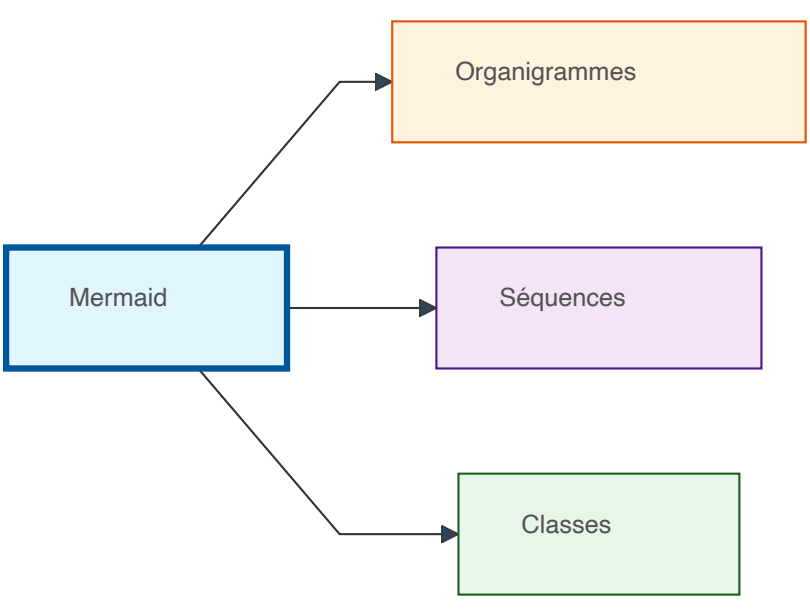

- création de web data app avec Streamlit
- notebooks **Marimo** (démo ici)

Librairie Python

- manipuler des données tabulaires: `polars` (user guide, comparaison avec pandas)
- création de visuels: `altair` (exemple)

Business Intelligence

Rendre interprétable et actionnable les données métiers.

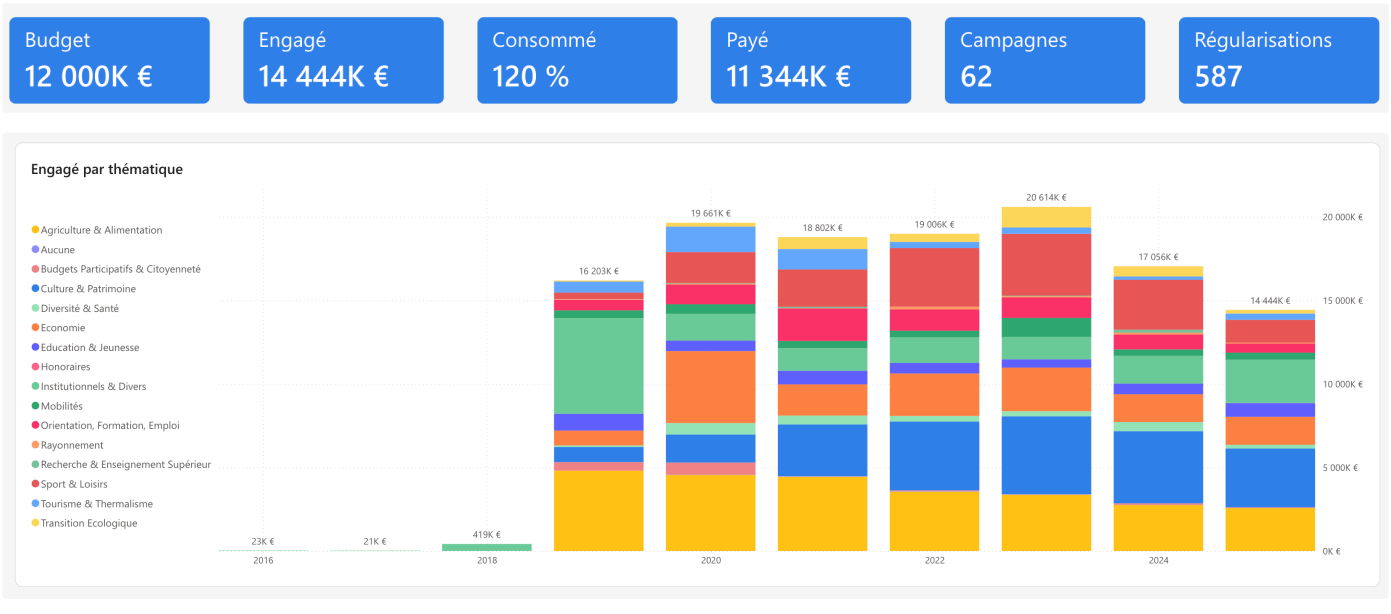

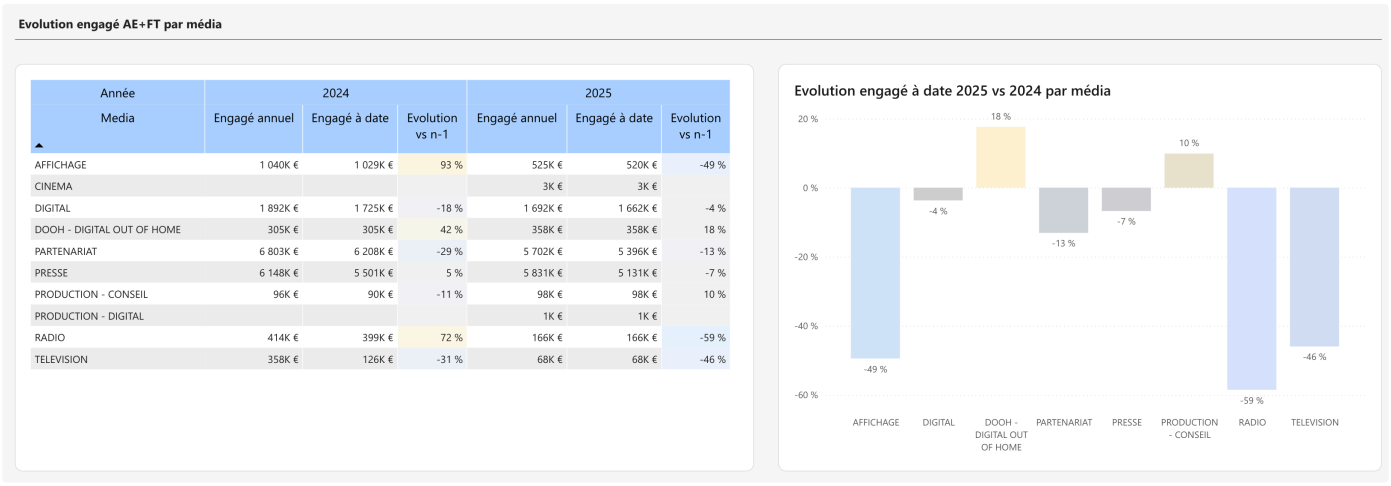

Décomposer un indicateur à partir de ses composantes →

- par catégorie (de produits, etc.)
- dans le temps
- calculer l'évolution en % YoY
- décomposer par quantité et panier moyen: Answering "Why did the KPI change?" using decomposition

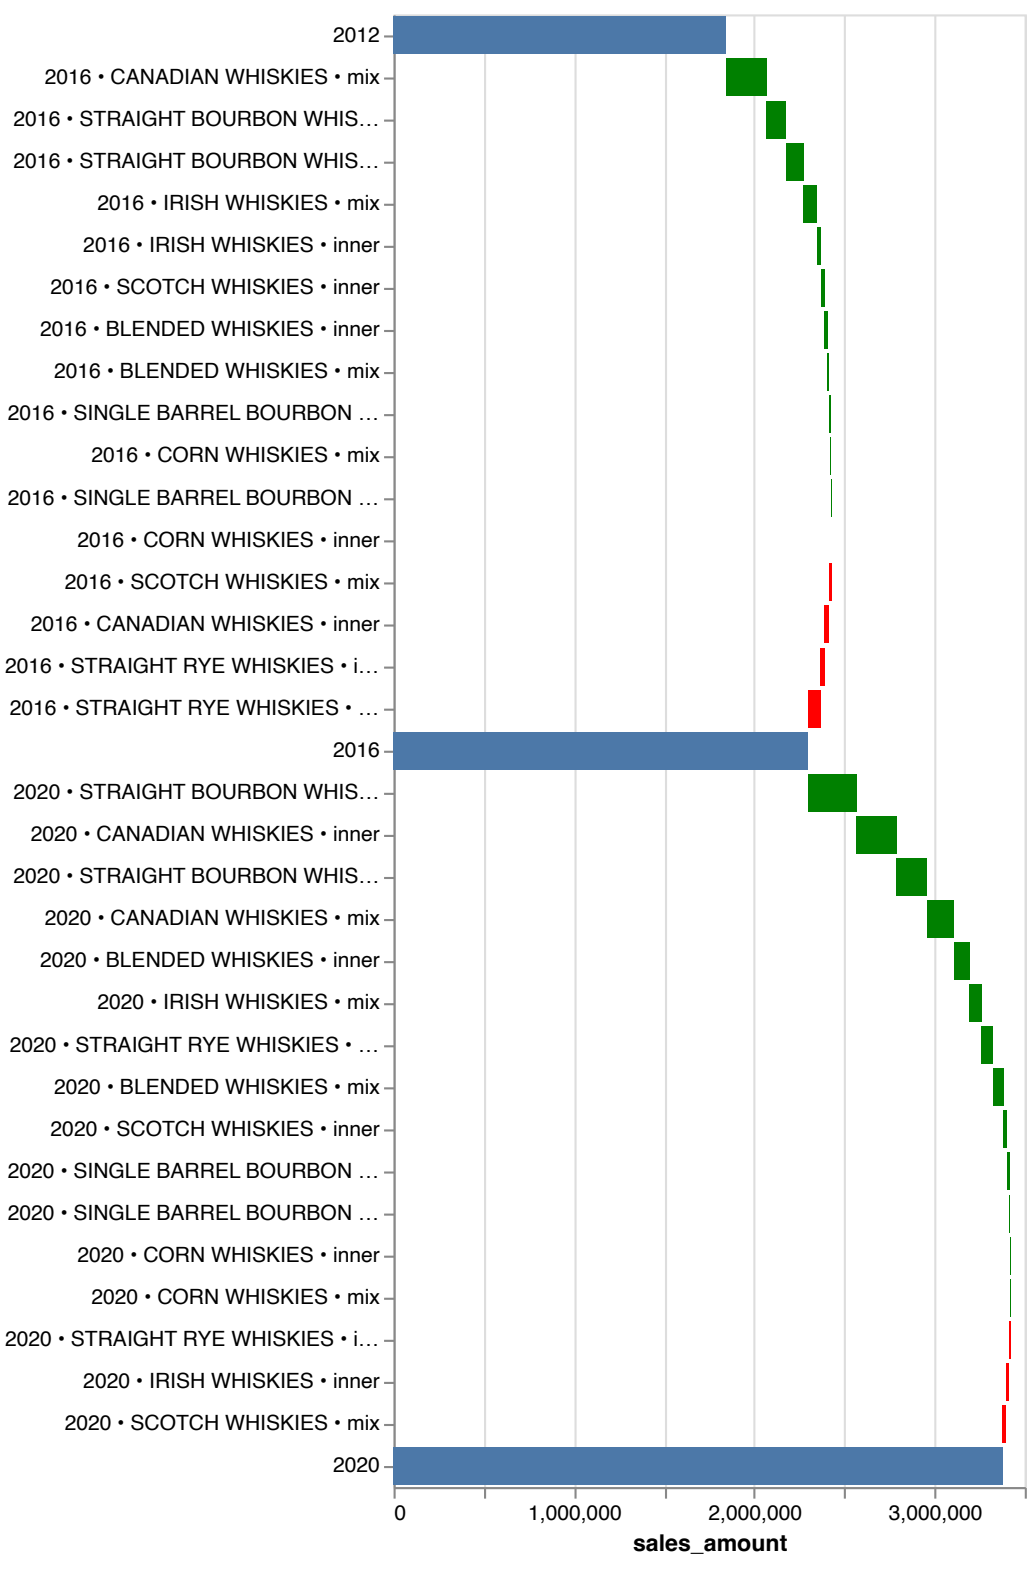

- fonctionne aussi avec des métriques de funnel (voir): `revenue = impressions * click_rate * conversion_rate * spend`

Package Python icanexplain

Considération autour des modèles de prédictions

- faut-il mieux prédire `prix total` ou bien `prix moyen` et `quantité` ?

  → prédire directement le prix total: offre généralement des meilleurs performance, modèle simple mais effet boîte noir

  → prédire indépendamment les deux variables:

  - explicite différents facteurs d'influence du `prix total`
  - meilleure interprétabilité et actionnabilité
  - permet d'isoler les erreurs et d'analyser la performance individuelle des modèles

Feature engineering

> **Objectif:** améliorer la performance d'un modèle en lui fournissant les données explicatives clés

1. apporter des données externes explicatives (ex: données de localisation)
2. transformant les features pour réduire la complexité du problème

Exemples de features engineering:

- faut-il mieux fournir: (hauteur et largeur) ou (surface et ratio hauteur/largeur)
- métrique dérivée: `ancienneté = aujourd'hui - date_creation`
- encodages cycliques: angle en degré, heure de la journée

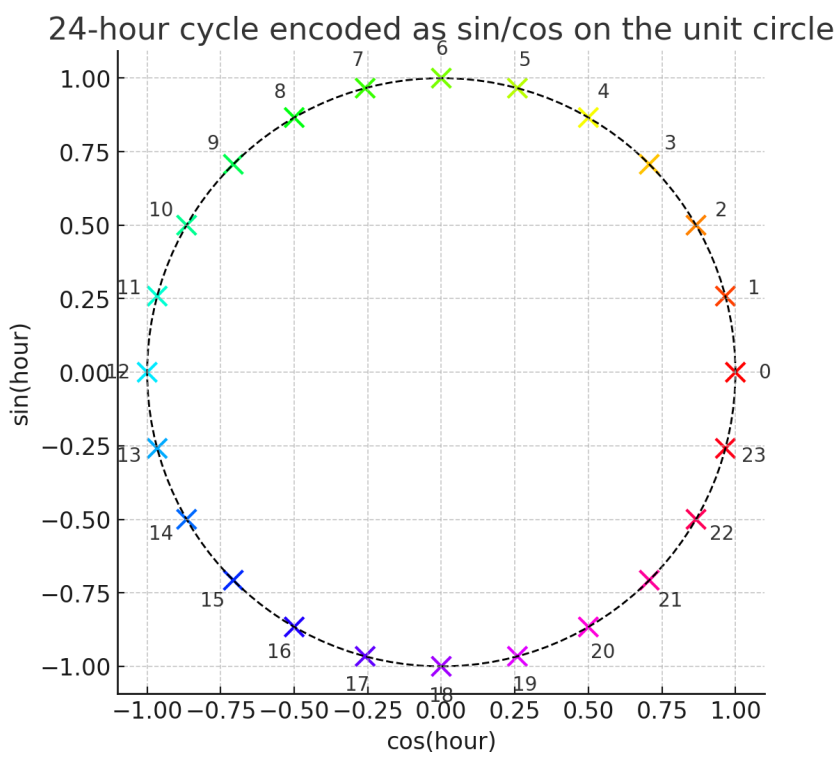

- encoder des coordonnées spatiales (x, y)
  - représentation polaire (angle + distance)
  - sans apport de données externes: K-means distance
  - avec des données externes: distances aux grandes villes
  - apport de données externes: démographique (population, niveau de revenu, etc.), géographique (surface, type de terrain), etc.
- données textuelles: TF-IDF (Term Frequency-Inverse Document Frequency)
- données temporelles: analyser les saisonalités à différentes échelles (par semaine, mois, jour de l'année) avec par exemple la transformée de Fourier ou vos connaissances métiers et ajouter des colonnes explicatives pertinente (`is_holiday` , `is_weekend`)
- cas de problèmes beaucoup plus complexe: comment encoder une position du jeu d'échec ? comment encoder une image ? comment encoder des données textuelles ? comment encoder le repliement de protéines ? (Geometric Deep Learning)

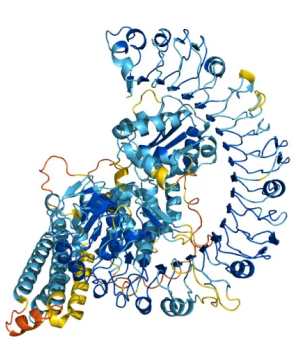

→ nombreux types de données ne possèdent pas une modélisation évidente / pleinement efficace

→ souvent une combinaison: features engineering avancé; architecture spécifique; grande puissance de calcul.

→ l'absence de modélisation pleinement efficace participe aussi à l'absence de robustesse des modèles.

Les pipelines sklearn

```python
import polars as pl

# Load data
df = pl.read_csv("../data/data.csv")

# Preprocess data at row-level check ✅
df = df.with_columns(
    [
        pl.col("date").dt.weekday().alias("weekday"),
        pl.col("date").dt.hour().alias("hour"),
        pl.col("date").dt.month().alias("month"),
    ]
)

# Preprocess data row using heuristics from dataset ❌
import polars.selectors as cs

df = df.with_columns(
    (cs.numeric() - cs.numeric().mean()) / cs.numeric().std()
)

# Preprocess data using sklearn pipeline ✅
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.compose import ColumnTransformer

numeric_features = df.select(cs.numeric()).columns
categorical_features = df.select(cs.categorical()).columns

preprocessor = ColumnTransformer(
    transformers=[
        ("num", StandardScaler(), numeric_features),
        ("cat", OneHotEncoder(handle_unknown="ignore"), categorical_features),
    ]
)

# Define model
```

```python
from sklearn.linear_model import LinearRegression

model = LinearRegression()

# Define pipeline
from sklearn.pipeline import Pipeline

pipeline = Pipeline(steps=[
    ("preprocess", preprocessor),
    ("regressor", LinearRegression())
])

# Used the same way as model
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
```

Pourquoi utiliser les pipelines `sklearn` :

- Regrouper pré-traitement + modèle dans un seul objet `pipeline`
- Éviter les fuites de données entre les jeux d'entraînement et de validation (lors d'un `test_train_split` ou `cross-validation`)
- Faciliter la réutilisation et le déploiement
- Simplifier la validation croisée et la recherche d'hyperparamètres:
    - `StandardScaler → PCA(n_components=0.7) → RandomForest(n_estimators=100)`
- Modularité et extensibilité → on peut facilement combiner plusieurs pipelines, créer des branches parallèles (`ColumnTransformer`), et insérer facilement de nouvelles étapes personnalisées (`FunctionTransformer`)

Sauvegarder un modèle

```python
from joblib import load, dump

# Train the model
model = model.fit(X_train, y_train)

# Save the model
dump(model, "../model/model.pkl")

# Load the model
model = load("../model/model.pkl")
```

MLFlow: Surveiller, enregistrer et réutiliser des modèles

- C'est quoi une API ?

L'écosystème d'outils data

- une base de données (OLTP ou OLAP)
- un outil d'ingestion de données
- un outil de transformation de données
- un outil de présentation des données
- un outil d'orchestration

SQL needs to die (plus d'infos ici et ici)

- SQL a très peu évolué depuis ses débuts
- SQL n'est pas standardisé (reste un langage relativement bas niveau des bases de données)
- SQL n'est pas aisément composable
- SQL n'a pas d'interface programmatique native
- SQL n'a pas connaissance des types de données
- duplication de la définition des données entre DB et applicatif

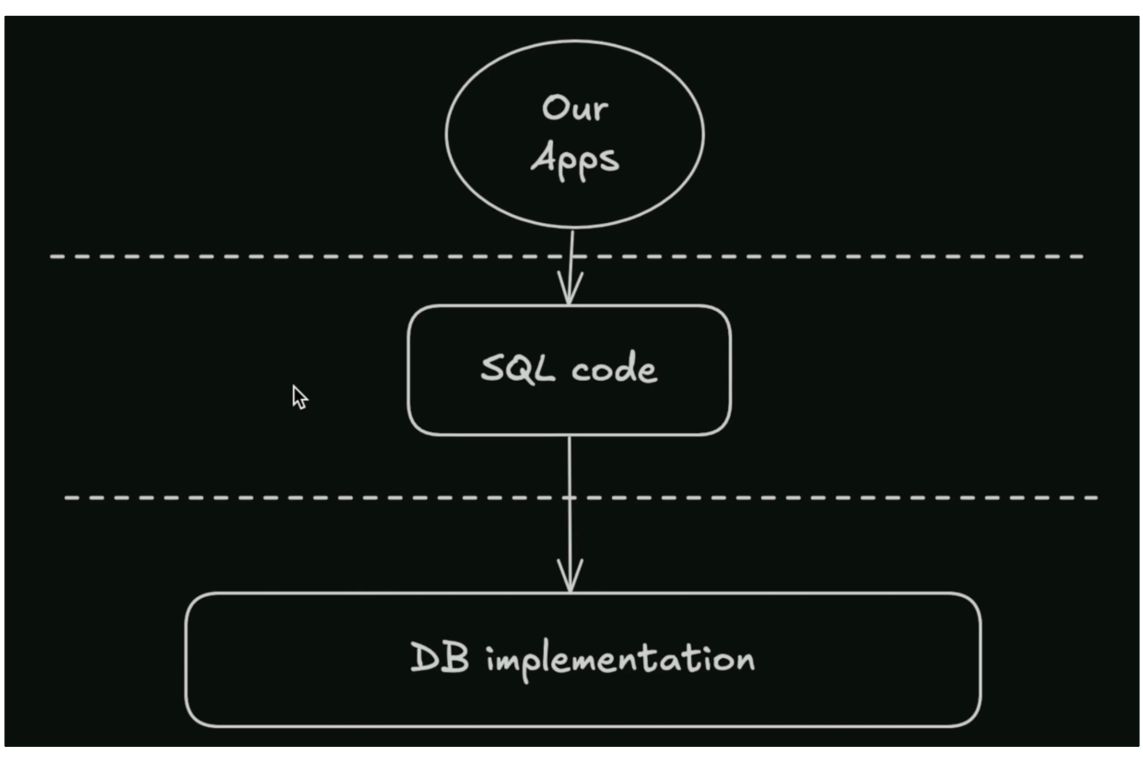

But SQL is still everwhere

- SQL reste toujours l'interface **finale** pour parler au moteur de la base de données
- La syntaxe SQL continue de s'améliorer (DuckDB - FriendlySQL: FROM avant SELECT, GROUP BY ALL, etc.)
- Côté applicatif: les ORM (object relational mapping) ou `sqlc`
- Côté analytique:
    - outils de transformation basée sur du SQL (dbt ou SQLMesh):
        - Plusieurs fichiers SQL sont responsables de nettoyer et structurer progressivement la donnée.
        - Ces outils comprennent le code SQL et créent des graphs de dépendances acycliques

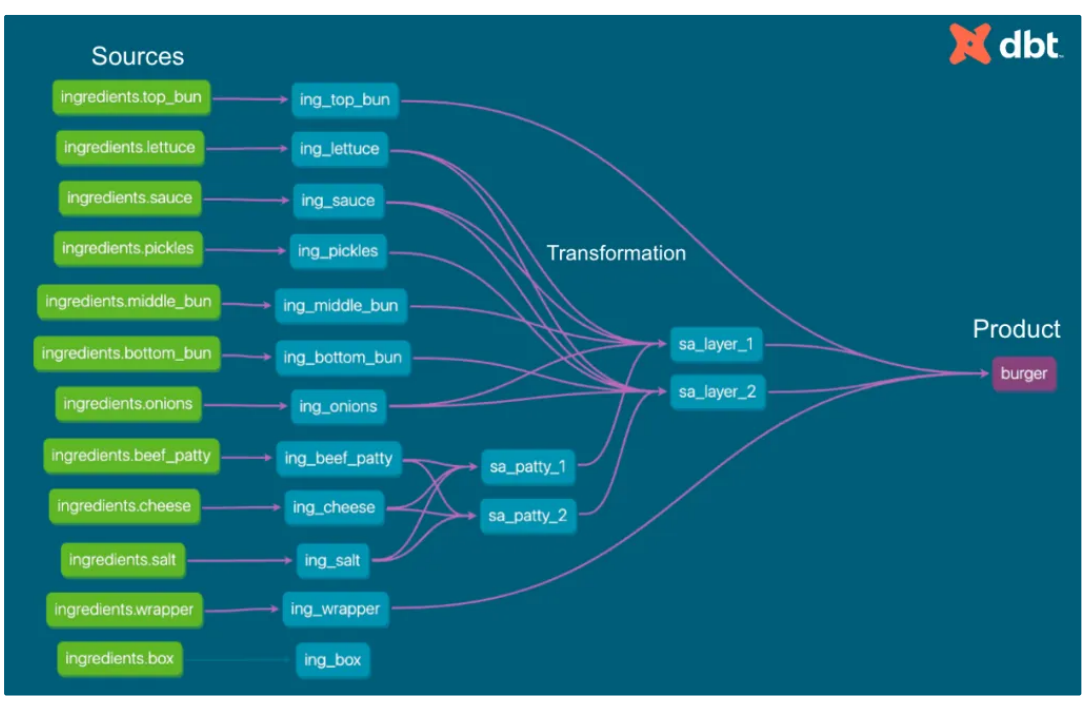

        - La compréhension du code SQL permet d'avoir du table ou du column level lineage.
        - Ces outils permettent de documenter directement les tables ou colonnes de la base de données
        - notion de layer sémantique (Modèle sémantique Power BI, LookML, Malloy.dev - blog de post) → malgré tout nécessaire car on ne peut pas tout pré-calculer et on peut aussi faire des jointures syntaxiquement valables mais qui n'ont pas de sens sémantiquement
    - modélisation dans l'entrepôt de données (modèle en étoile - table de faits et de dimensions)

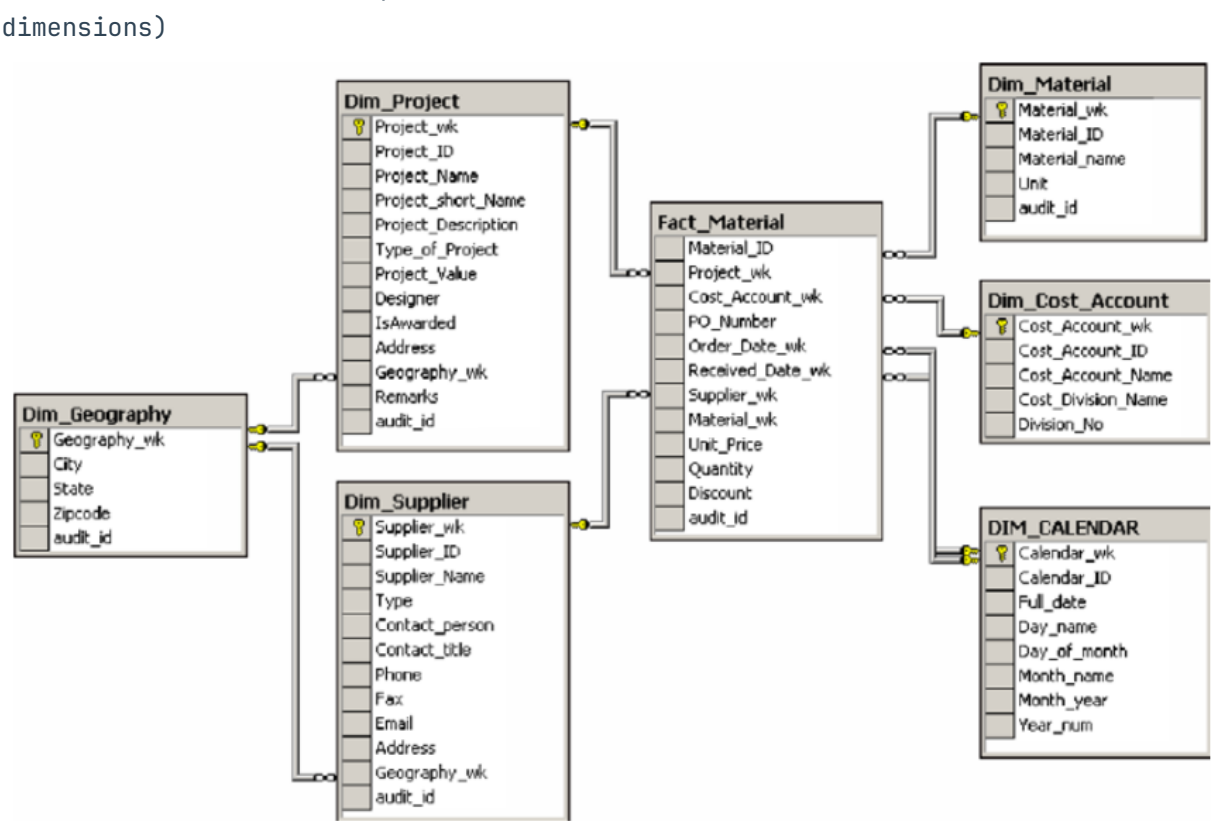

Tendances globales:

- nouveaux outils cloud avec des interfaces modernes (Snowflake, Databrick, AirByte, Superset) mais il existe toujours des outils legacy (Talend, QLick, Microsoft SSIS)
- de plus en plus de pratiques issues du développement: des outils déclaratifs, versioning, tests unitaires, type hint, etc.
- implémentation de référence: GitLab Data